Artefactos de movimiento en PPG

Álvaro Martín, Elisa Fernández Morales, Thomas Michael Spitzner
Procesamiento Adaptativo de Señales (22.46) — Profesor: Marc S. Ressl
Instituto Tecnológico de Buenos Aires (ITBA), Buenos Aires, Argentina
Legajos: 69507, 69616, 69453 — Email: {almartin, efernandezmorales, tspitzner}@itba.edu.ar

***Resumen*—Este informe presenta un método para eliminar los artefactos de movimiento de las señales de fotopletismografía (PPG) para después estimar la frecuencia cardíaca de una persona.**

I. Introducción

En este trabajo se estudia la cancelación de artefactos de movimiento en señales de fotopletismografía (PPG) mediante filtros adaptativos, con el objetivo de estimar la frecuencia cardíaca. En esta sección se presenta el proyecto, comenzando por las señales de PPG (Sección I-A). Después se discuten la elección del dataset y la organización exacta de los datos (Sección I-B).

A. Presentación de las señales

Las señales de fotopletismografía (PPG) son señales creadas por una técnica óptica, donde una luz verde es emitida y después el reflejo de esta luz es recibido por un fotodiodo. La potencia de esta señal reflejada puede ser utilizada para medir los cambios de volumen sanguíneo. Esencialmente, cuando hay más sangre, la luz verde es absorbida por la hemoglobina y el reflejo tiene menos intensidad y viceversa. Entonces una señal de PPG sin ruido puede estimar cambios de sangre, y en turno el ritmo cardíaco de una persona.

Igualmente, el problema con las señales de PPG es que simplemente miden el reflejo de una luz emitida. Esta medición puede tener mucha interferencia, por ejemplo, el movimiento del emisor y el receptor. Este ruido es conocido como "motion artifacts", y para poder tener una buena estimación del flujo de sangre es necesario tener la señal de PPG limpia.

El uso más común de estas señales es en los relojes inteligentes, y como será explicado en Sección I-B, la base de datos que escogimos es de dispositivos de muñeca. El gran beneficio es que la mayoría de estos relojes tienen acelerómetros, que pueden medir el movimiento de la persona y en turno se pueden usar para eliminar los efectos del movimiento en la señal de PPG.

La estructura exacta de los datos será presentada en Sección I-B, pero para establecer una intuición de estas señales, una parte del dataset es visualizada en Fig. 1. Como se puede ver, la señal PPG evidentemente tiene una frecuencia, el ritmo cardíaco de la persona, pero no es perfecta. La frecuencia no siempre es constante, la potencia de los picos no es siempre igual e incluso hay veces donde no se puede ver ninguna frecuencia presente.

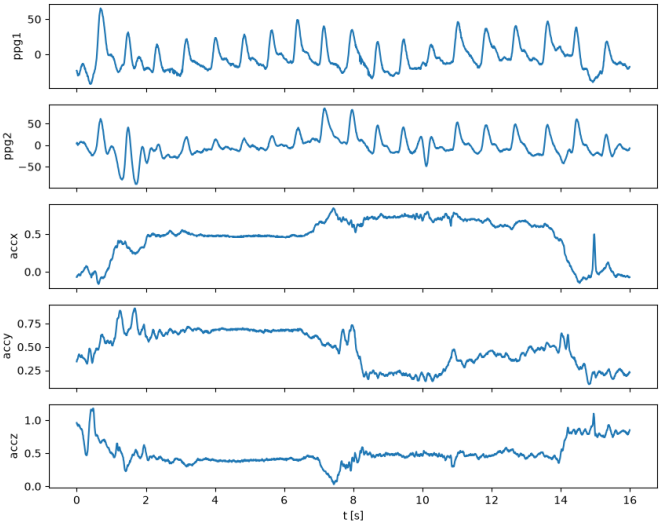


Fig. 1. Gráficos de los datos presentes en la base de datos IEEEPPG [1] (esta imagen fue creada utilizando nuestro código).

En cambio, las señales de los acelerómetros son irregulares y no estacionarias ya que simplemente describen el movimiento de una persona. Igualmente se debería notar que pueden ser periódicas si el movimiento de la persona sigue un ritmo constante, como por ejemplo el movimiento de los brazos mientras corres.

B. Organización de datos

Todos los datos para este proyecto se obtuvieron de la base de datos de IEEEPPG [1]. La estructura de los datos es presentada visualmente en Fig. 2. Como se puede ver en la figura, la base de datos consiste en dos señales de PPG, una para cada fotodiodo (dos pulsioxímetros separados unos 2 cm en la muñeca), y tres señales del acelerómetro (ejes x, y y z), que serán utilizadas como las señales de referencia (esto será presentado en más detalle en Sección II-A).

También se debería aclarar que estos datos fueron obtenidos de dispositivos de muñeca utilizados durante ejercicio físico, entonces gran parte de las señales de PPG tienen un ruido significativo. Además, estos datos se obtuvieron a una frecuencia de 125 Hz.

Esta base de datos también contiene la frecuencia cardíaca de referencia (BPM), calculada a partir de un electrocardiograma (ECG) medido en el pecho. Es un dato útil para calcular el

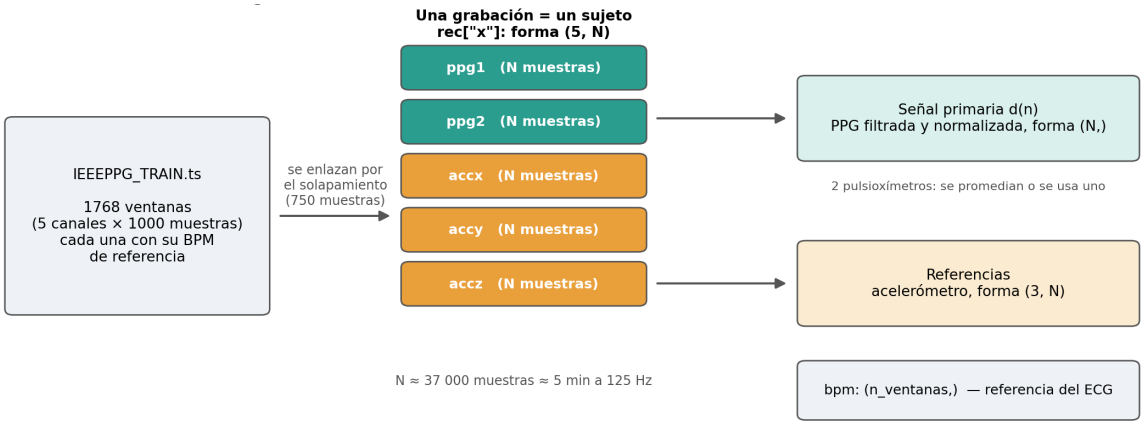


Fig. 2. Organización de los datos en la base de datos IEEEPPG [1] (esta imagen fue creada utilizando Claude).

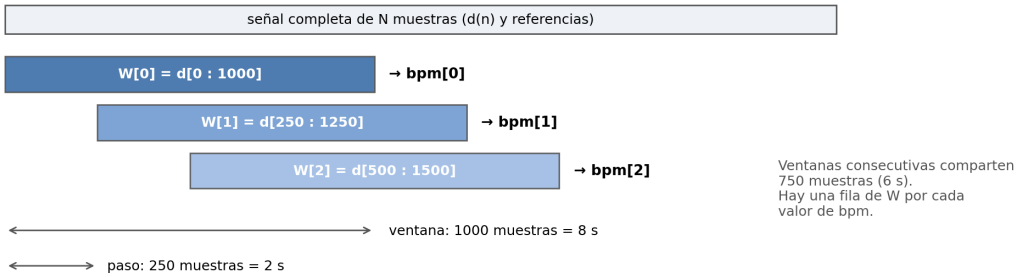


Fig. 3. Ventaneo de los datos en la base de datos IEEEPPG [1] (esta imagen fue creada utilizando Claude).

error de nuestras estimaciones respecto de esta referencia, y a su vez poder cuantificar el rendimiento de nuestros algoritmos.

Los datos están divididos en diferentes ventanas de 8 s (1000 muestras) que avanzan de a 2 s, es decir, cada una con un overlap de 6 s con la siguiente, y cada ventana tiene como referencia el BPM de referencia para esa ventana. Figure 3 presenta una visualización del ventaneo presente en los datos.

En total había 22 participantes, y los datos fueron divididos en dos: un set de entrenamiento (12 participantes) y un set de prueba (10 participantes). Esto equivale a 1768 ventanas de entrenamiento y 1328 ventanas de prueba. Este proyecto utilizará esta estructura predeterminada de los datos para ajustar los hiperparámetros de los algoritmos con el set de entrenamiento (mediante validación cruzada por participante), escoger el algoritmo óptimo, y al final comparar el rendimiento de cada método con el set de prueba.

II. Marco teórico

Esta sección presenta el marco teórico sobre los filtros adaptativos que fueron empleados para limpiar la señal de PPG. En primer lugar, Sección II-A presenta el esquema de cancelación de interferencia empleado, y después Sección II-B expone las variantes del algoritmo LMS que escogimos para eliminar el ruido de las señales y las razones por las cuales decidimos usarlas.

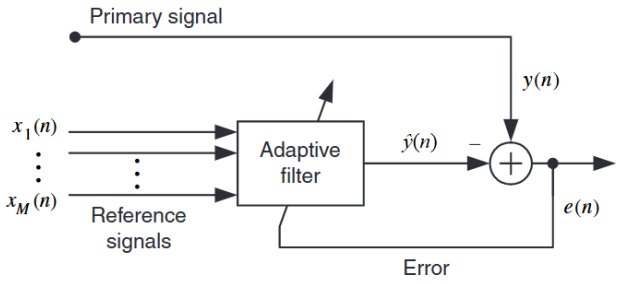


Fig. 4. Esquema de cancelación de interferencia (este gráfico fue obtenido del material de curso Procesamiento Adaptativo de Señales (22.46)) [2].

A. Esquema escogido

En primer lugar, en la Fig. 4 se puede visualizar el rol de los filtros adaptativos en nuestra implementación. Cada una de las dos señales de PPG es una señal primaria, ya que contiene la información pero también tiene ruido. Un punto importante es que tenemos dos señales primarias, entonces la combinación de estas dos señales (una fusión) es una decisión de diseño que es discutida en Sección III.

Aparte de esto, tenemos las señales de referencia que en este caso son los tres ejes del acelerómetro. Se implementa un

filtro adaptativo, y con estas señales de referencia se estima la parte de la señal primaria que corresponde al movimiento. Para esto, el filtro utiliza las últimas M muestras de cada eje, y no solo la muestra actual. La salida de este filtro va a ser la estimación, $\hat{y}$, que representa la parte de la señal de PPG que está correlacionada con el movimiento medido por el acelerómetro.

Esta estimación debería contener las partes de la señal de PPG que son debidas al ruido de movimiento. El ruido que no tiene relación con el acelerómetro no puede ser cancelado de esta manera. Entonces, si sustraemos esta señal de la primaria debería quedar la señal de PPG limpia, que en el esquema es el error, es decir, la salida del sistema. Esto funciona bajo el supuesto de que el latido no está correlacionado con el movimiento, ya que en caso contrario el filtro también cancelaría parte del latido.

B. Variantes de LMS escogidas

Escogimos tres variantes diferentes de LMS. En primer lugar implementamos el LMS normal, por varias razones. La primera es que tiene la implementación más fácil ya que solo tenemos dos hiperparámetros para optimizar, M y μ (además de $\mathbf{w}[0]$, que en las tres variantes inicializamos en cero). Además, también podemos comparar el rendimiento de las otras variantes con el rendimiento de LMS para entender mejor el beneficio de usar las alternativas. Finalmente, como es la más fácil y menos complicada de implementar, si tiene resultados similares al resto de variantes entonces no hace falta usar una variante más compleja, simplemente podemos utilizar LMS estándar.

1) LMS estándar: El LMS estándar se puede describir con (1), donde μ determina la velocidad de avance, $\mathbf{a}[n]$ es el vector de entrada (las últimas M muestras de cada eje del acelerómetro) y $e[n]$ es la señal de error, que en un caso óptimo debería ser la señal de PPG limpia.

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \mu\, e[n]\, \mathbf{a}[n] \tag{1}$$

2) NLMS: Otra variante de LMS que implementamos fue NLMS. El beneficio que tiene NLMS con respecto a LMS es que normaliza el parámetro de paso con respecto a la energía instantánea del vector de entrada, por lo tanto si la energía varía con el tiempo esto afecta menos el rendimiento de NLMS.

Esto está presentado en (2), donde la ecuación es igual a la de LMS pero el parámetro de paso μ es dividido por la energía del vector de entrada, $\|\mathbf{a}[n]\|^2$. También tiene el parámetro δ para evitar que el paso explote cuando la energía de la entrada sea muy cercana a cero.

Esta variante sería útil en este caso porque la energía de los acelerómetros varía, dentro de una misma ventana, dependiendo de la acción que esté tomando el usuario con el dispositivo. Si no se está moviendo entonces los acelerómetros tendrán poca energía, pero si el usuario corre o hace deporte más intenso, entonces la energía de la señal podría aumentar mucho en algunos instantes. Aunque normalizamos las señales de cada ventana, esto solo corrige la diferencia de potencia entre ventanas, y no los cambios dentro de una ventana. Por lo tanto, para independizar el rendimiento del algoritmo de la energía de la señal de entrada NLMS sería una variante interesante.

La desventaja que tiene comparado a LMS es que tenemos que optimizar 3 hiperparámetros (M, μ y δ), por lo tanto la optimización lleva más tiempo de cómputo.

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \frac{\mu}{\delta + \|\mathbf{a}[n]\|^2}\, e[n]\, \mathbf{a}[n] \tag{2}$$

3) VS-LMS: Finalmente, Variable Step Size LMS (VS-LMS) también sería útil en nuestro caso. Cada ventana dura solo 8 s y el filtro arranca con $\mathbf{w}[0] = \mathbf{0}$, por lo que necesitamos un paso grande al comienzo para converger rápido, pero uno más chico después para que el error en régimen estacionario sea bajo, algo que un paso fijo no puede lograr. Además, el filtro se puede alejar muy rápidamente del óptimo si las señales de entrada cambian mucho. Como fue discutido cuando se presentó NLMS esto es algo esperado en esta aplicación, ya que un cambio de movimiento rápido podría causar que las señales de referencia cambien mucho y debido a esto nos podríamos alejar del óptimo que ya había encontrado el algoritmo anteriormente.

VS-LMS soluciona esto cambiando la magnitud de nuestros pasos dependiendo del error. Si el error es grande, entonces probablemente estamos lejos del óptimo y este algoritmo aumenta el parámetro de paso μ para llegar al óptimo más rápidamente. En cambio, si el error es pequeño, el parámetro de paso decae para no alejarnos del óptimo y evitar un "bamboleo" alrededor de él. Esencialmente, este algoritmo debería aumentar la velocidad de convergencia cuando las señales de referencia cambien, que es algo esperado de los datos.

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \frac{\mu[n]}{\delta + \|\mathbf{a}[n]\|^2}\, e[n]\, \mathbf{a}[n] \tag{3}$$

Como se puede ver, VS-LMS usa la misma normalización que NLMS, por lo que comparar estas dos variantes permite aislar el efecto del paso variable.

También se debería notar que se añadió un límite máximo y mínimo para el parámetro de paso, como se puede ver en (4), para asegurar que el algoritmo no se vuelva inestable o que el μ sea tan pequeño que nunca llegue al óptimo.

$$\mu[n+1] = \mathrm{clip}\left(\alpha \cdot \mu[n] + \gamma \cdot e^2[n],\ \mu_{\min},\ \mu_{\max}\right) \tag{4}$$

Similarmente al NLMS la desventaja que tiene este algoritmo comparado al LMS es que tenemos 5 hiperparámetros para optimizar (M, $\mu_{\max}$, $\mu_{\min}$, α y γ), además de δ y $\mathbf{w}[0]$, que se fijan en 1 y en cero, y de $\mu[0]$, que es igual a $\mu_{\max}$. Por lo tanto, la optimización lleva más tiempo de cómputo. Como se mencionó anteriormente, por eso estamos utilizando LMS como referencia, porque si los resultados son similares, no conviene usar una variante más compleja, pero si realmente mejora el rendimiento, entonces debería ser explorado.

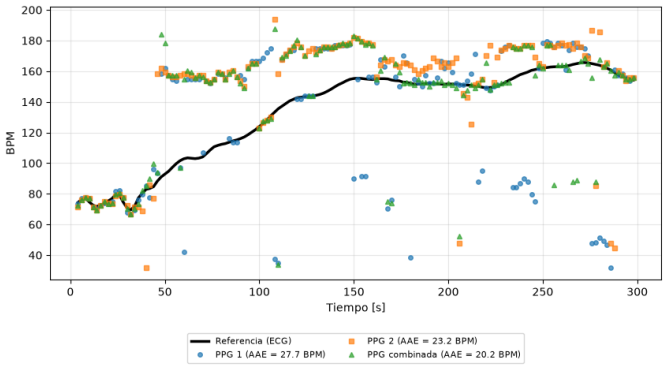


Fig. 5. Esquema representando el BPM calculado utilizando la señal PPG sin limpiar, comparado al BPM correcto.

III. Metodología

Esta sección presenta lo que hace el código implementado para estimar el BPM, también explicando las decisiones que se tomaron antes de programar el código. En primer lugar, en Sección III-A simplemente estimamos el BPM de la PPG sin aplicar ningún filtrado, para intentar tener un mejor conocimiento de los datos. Después, Sección III-B presenta todo el preprocesamiento que se hizo a los datos antes de emplearlos. Subsecuentemente, los métodos para estimar el BPM son comparados en Sección III-C y finalmente las decisiones tomadas para elegir los hiperparámetros se presentan en Sección III-D.

A. Aproximando el BPM con la PPG sin filtrar

Lo primero que hace el código es estimar el BPM con las dos señales de entrada. El método exacto utilizado para estimar el BPM es discutido en Sección III-C, pero conviene presentar la Fig. 5 primero para mejorar la intuición de los datos.

Como presenta esta figura, el BPM fue estimado de tres maneras, utilizando cada una de las señales de PPG individualmente y también tomando el promedio de ambas.

Este gráfico desvela dos puntos significativos. En primer lugar, desde 0–50 s y desde 150 s hasta el final la estimación del BPM es relativamente buena. Esto es probablemente debido a que no hubo mucho movimiento durante estos tramos, entonces nos muestra que si no hay "motion artifacts" la señal de PPG es muy limpia y estima bien el BPM.

El segundo punto que se puede ver es que hay instantes donde una de las dos señales de PPG es una muy buena estimación del BPM mientras que la otra está muy mala. Esto tiene sentido físicamente, ya que como son dos fotodiodos diferentes podría haber movimientos que solo afectan a uno de los dos.

Sabiendo esto, no conviene tomar las dos señales como iguales y utilizar un promedio, sino que conviene combinarlas dependiendo del ruido de cada una. Entonces para crear la señal primaria, multiplicamos las dos señales por un peso dependiendo del SNR de cada señal, como se puede ver en (5).

$$\text{PPG}_{\text{primaria}} = w_1 \cdot \text{PPG}_1 + w_2 \cdot \text{PPG}_2 \tag{5}$$

El peso exacto se obtuvo con (6) (`compute_snr_weights` y `snr_weighted_late_fusion`):

$$w_1 = \frac{\text{SNR}_1}{\text{SNR}_1 + \text{SNR}_2}, \qquad w_2 = \frac{\text{SNR}_2}{\text{SNR}_1 + \text{SNR}_2} \tag{6}$$

B. Preprocesado

Para cada ventana utilizada lo primero que se hizo fue implementar un preprocesamiento. Este procesamiento se hizo en el módulo `preprocessing.py` y consiste en dos operaciones.

En primer lugar, cada canal (las dos señales de PPG y los tres acelerómetros) es filtrado con un pasabanda Butterworth de cuarto orden. Las frecuencias límite fueron $[f_{\text{lo}}, f_{\text{hi}}] = [0.5, 4.0]$ Hz, que corresponden a un ritmo cardíaco entre 30 y 240 BPM. En nuestro modo de procesamiento por ventanas no causal, el filtro se aplica en sentido directo e inverso mediante secciones de segundo orden (`scipy.signal.sosfiltfilt`), lo que da lugar a una respuesta en magnitud de fase cero de octavo orden efectivo. Este filtro pasabanda fue aplicado porque el ritmo cardíaco de una persona siempre se encuentra en el rango de estas frecuencias, entonces analizar las partes de las señales fuera de este rango de frecuencia aumentaría la cantidad de datos analizados sin ofrecer información relevante para calcular el ritmo cardíaco.

Después de aplicar el filtro pasabanda cada canal es normalizado en la función `normalize_amplitude`. Esta normalización ocurre a lo largo de las $N = 1000$ muestras de la ventana para obtener una media cero y una varianza unitaria:

$$\tilde{x}_c[n] = \frac{x_c[n] - \mu_{x_c}}{\sigma_{x_c} + \epsilon},$$
$$\mu_{x_c} = \frac{1}{N}\sum_{n=0}^{N-1} x_c[n], \quad \sigma_{x_c} = \sqrt{\frac{1}{N}\sum_{n=0}^{N-1}(x_c[n] - \mu_{x_c})^2}, \tag{7}$$

Estas ecuaciones son las ecuaciones de normalización estándar, con el término $\epsilon = 10^{-8}$ añadido para asegurar que no haya división por cero, que podría causar problemas de estabilidad numérica. Esta normalización es esencial para el filtrado adaptativo, ya que la señal de PPG varía entre ± 20 y ± 150, mientras que las señales de los acelerómetros podrían variar entre ± 0.1 y ± 3.0, una diferencia de dos órdenes de magnitud. Aplicar la normalización asegura que la matriz de correlación $\mathbf{R_a} = \mathbb{E}[\mathbf{a}[n]\mathbf{a}^T[n]]$ tenga una traza acotada, $\text{Tr}(\mathbf{R_a}) \approx 3M$. Esto permite que los hiperparámetros escogidos puedan ser aplicados en todos los diferentes casos.

Entonces este preprocesamiento limita los datos al rango que nos interesa para encontrar el ritmo cardíaco y también normaliza todos los datos para asegurar que los mismos hiperparámetros optimizados puedan ser utilizados en todos los casos.

C. Estimación del BPM

Para estimar el BPM se utilizaron dos métodos diferentes: un periodograma y un detector de picos de Elgendi. Ambos métodos fueron implementados para las diferentes variantes

de LMS, y después el rendimiento de ambos fue comparado para escoger el que funcione mejor para los datos que estamos utilizando.

1) Periodograma modificado con zero-padding: En primer lugar estimamos el BPM con un periodograma modificado con zero-padding (`zero_padded_periodogram_bpm`). La señal de error, que representa la señal de PPG limpia, es multiplicada por una ventana de tapering $v[n] \in \{\text{Hann}, \text{Hamming}, \text{Blackman}\}$ para suprimir la fuga en los lóbulos laterales espectrales. Después se aplica un zero-padding hasta alcanzar una longitud NFFT $\in \{4096, 8192\}$ y se realiza la transformación mediante la Transformada Rápida de Fourier (FFT):

$$S(f_k) = \frac{1}{N\|v\|^2} \left| \sum_{n=0}^{N-1} e_{\text{fused}}[n]\, v[n]\, e^{-j2\pi kn/\text{NFFT}} \right|^2, \qquad f_k = \frac{k \cdot f_s}{\text{NFFT}}. \tag{8}$$

Sin aplicar zero-padding, la resolución del DFT nativo es $\Delta f = 0.125$ Hz $= 7.5$ BPM, que podría introducir un error de cuantización de hasta ± 3.75 BPM. El zero-padding reduce el paso de la grilla de frecuencias a $\Delta f = \frac{125}{8192} \times 60 = 0.9155$ BPM, lo que permite ubicar el pico con más precisión (aunque no mejora la resolución real del periodograma). Después, para obtener el ritmo cardíaco, tenemos que calcular el pico más grande en el dominio de la frecuencia:

$$\hat{y}_{\text{per}} = 60 \cdot \arg \max_{f_k \in [0.5, 4.0]\ \text{Hz}} S(f_k). \tag{9}$$

2) Detector de picos de Elgendi: También utilizamos un algoritmo detector de picos de Elgendi (`elgendi_systolic_peak_bpm`), basado en el informe escrito por Elgendi [3]. En primer lugar, la señal limpia de PPG (la señal de error en el esquema presentado en Sección II-A) es elevada al cuadrado con un recorte positivo $z[n] = (\max(e_{\text{fused}}[n], 0))^2$.

Después esta señal es procesada utilizando dos ventanas móviles: una ventana corta W_1, correspondiente a la duración sistólica ($\text{MA}_{\text{peak}}[n]$), y una ventana más larga W_2, correspondiente a la duración de un latido cardíaco ($\text{MA}_{\text{beat}}[n]$). Utilizando estas ventanas, se buscan momentos en los que la señal de la ventana corta supera a la de la ventana larga por un margen determinado, $\text{MA}_{\text{peak}}[n] > \text{MA}_{\text{beat}}[n] + \beta \cdot \bar{z}$. Entonces, si estas zonas tienen una duración mínima de W_1, se buscan en ellas los picos sistólicos.

Finalmente, se calcula $\hat{y}_{\text{elg}}$ utilizando la mediana del tiempo entre latidos consecutivos (IBI).

D. Elección de hiperparámetros

Para elegir los hiperparámetros de cada variante de LMS y del detector de BPM sin caer en sobreajuste (*overfitting*), implementamos un esquema de optimización en el módulo `optimization.py`.

Primero, hay un problema importante con la base de datos: las ventanas consecutivas de un mismo participante tienen una superposición de 6 s (750 muestras). Si repartiéramos las ventanas al azar entre entrenamiento y validación, habría fuga de información (*data leakage*), ya que dos ventanas casi idénticas podrían caer en particiones distintas. Para evitar esto, en `dataset_preparation.py` implementamos la función `split_participants`, que detecta a qué participante pertenece cada ventana buscando la coincidencia exacta de esas 750 muestras solapadas. Con esta información, la función `subject_wise_group_kfold` divide las 1768 ventanas de entrenamiento en $K = 5$ particiones (*Group K-Fold*) agrupadas estrictamente por participante. De esta manera, en cada *fold* todas las ventanas de una misma persona quedan o en entrenamiento o en validación, nunca en las dos.

Segundo, para decidir qué tan buena es una configuración de hiperparámetros definimos una función objetivo compuesta (`objective_function` en `bpm_detection.py`), presentada en (10). Si solo minimizáramos el error absoluto medio (AAE), una configuración con errores muy grandes en unas pocas ventanas podría parecer igual de buena que una con errores moderados en todas. Por esto la función también incluye la raíz del error cuadrático medio (RMSE), que penaliza la dispersión del error, y un término lineal para los errores graves (*outliers*) que superan el umbral de 10 BPM:

$$\mathcal{L}(\hat{\mathbf{y}}, \mathbf{y}) = \text{AAE} + 0.35 \cdot \text{RMSE} + 0.50 \cdot \frac{1}{N_w} \sum_{i=1}^{N_w} \max\left(0,\ |\hat{y}_i - y_i| - 10\right), \tag{10}$$

donde N_w es la cantidad de ventanas evaluadas, $\text{AAE} = \frac{1}{N_w} \sum_{i=1}^{N_w} |\hat{y}_i - y_i|$ y $\text{RMSE} = \sqrt{\frac{1}{N_w} \sum_{i=1}^{N_w} (\hat{y}_i - y_i)^2}$.

Para que la comparación entre los tres algoritmos sea justa, optimizamos cada variante (`standard_lms`, `nlms` y `vs_lms`) de manera independiente con un estimador de Parzen estructurado en árbol (`ConditionalTPE`), dentro de los rangos de la Tabla I. En todos los casos el orden del filtro M por eje del acelerómetro se buscó entre 6 y 24 muestras (entre 18 y 72 coeficientes en total para los tres ejes).

Finalmente, para reducir el tiempo de cómputo, dividimos la búsqueda (`optimize_hr_pipeline`) en dos fases por cada variante de LMS:

1. **Fase 1 (filtrado rápido)**: Evaluamos 12 configuraciones candidatas sobre un subconjunto fijo de 150 ventanas de entrenamiento, con un periodograma rápido (NFFT $=$ 4096), y nos quedamos con las 2 mejores de cada variante.
2. **Fase 2 (optimización completa)**: Hacemos 14 pruebas por variante evaluando los 5 *folds* completos de la validación cruzada por participante. Las primeras pruebas parten (*warm start*) de las mejores configuraciones de la Fase 1 combinadas con los dos detectores de BPM (periodograma y Elgendi), y las siguientes son guiadas por `ConditionalTPE`. Además usamos un podador por mediana (`MedianFoldPruner`): si el puntaje acumulado de una configuración en los primeros *folds* es peor que el percentil 50 de las pruebas anteriores, dejamos de evaluarla.

TABLA I
ESPACIO DE BÚSQUEDA CONDICIONAL DE HIPERPARÁMETROS PARA LAS VARIANTES DE LMS Y LOS MÉTODOS DE ESTIMACIÓN DE BPM.

Etapa / Algoritmo	**Hiperparámetro**	**Rango / Valores explorados**
LMS estándar (`standard_lms`)	Orden por eje M	$\{6, 7, \ldots, 24\}$
	Paso μ	$[10^{-4},\ 2.5 \times 10^{-3}]$ (escala log.)
NLMS (`nlms`)	Orden por eje M	$\{6, 7, \ldots, 24\}$
	Paso normalizado μ	$[0.005,\ 0.10]$ (escala log.)
	Regularización δ	$[0.5,\ 5.0]$ (escala log.)
VS-LMS (`vs_lms`)	Orden por eje M	$\{6, 7, \ldots, 24\}$
	Paso máximo $\mu_{\max}$	$[0.01,\ 0.12]$ (escala log.)
	Paso mínimo $\mu_{\min}$	$[0.001,\ 0.01]$ (escala log.)
	Factor de olvido α	$[0.95,\ 0.995]$
	Sensibilidad al error γ	$[10^{-4},\ 5 \times 10^{-3}]$ (escala log.)
Periodograma (`periodogram`)	Longitud FFT (NFFT)	$\{4096,\ 8192\}$
	Ventana $v[n]$	{Hann, Hamming, Blackman}
Detector de Elgendi (`elgendi`)	Ventana sistólica W_1	$[0.08,\ 0.14]$ s
	Ventana de latido W_2	$[0.55,\ 0.80]$ s
	Umbral β	$[0.01,\ 0.08]$

IV. RESULTADOS

En esta sección presentamos los resultados de aplicar nuestro sistema de cancelación adaptativa de artefactos de movimiento sobre la base de datos IEEEPPG [1], donde cada ventana de 8 s se procesa por separado, sin ningún contexto de las ventanas anteriores. En Sección IV-A mostramos los hiperparámetros óptimos y el rendimiento de cada variante en la validación cruzada. Después, en Sección IV-B evaluamos qué tan bien generalizan los algoritmos sobre el conjunto de prueba (`IEEEPPG_TEST.ts`), separando el error por variante y por participante. Finalmente, en Sección IV-C mostramos paso a paso cómo se transforma una ventana a lo largo del *pipeline*, y comparamos un caso exitoso con un caso atípico (*outlier*).

A. Optimización de hiperparámetros y validación cruzada

La Tabla II resume los hiperparámetros óptimos de cada variante de LMS y su rendimiento promedio en los 5 *folds* de la validación cruzada por participante, sobre el conjunto de entrenamiento (1768 ventanas de 12 participantes). Como referencia incluimos la línea base sin LMS, que es el BPM estimado directamente sobre las señales de PPG preprocesadas y combinadas por SNR, sin pasar por el filtro adaptativo.

De los resultados de la validación cruzada podemos llegar a tres conclusiones:

1. **El filtrado adaptativo mejora mucho la estimación**: Las tres variantes de LMS mejoran claramente la señal sin filtrar. El AAE baja de 12.52 BPM a entre 4.56 y 5.18 BPM (una reducción de hasta $63.6\,\%$), y el porcentaje de ventanas con errores graves (> 10 BPM) baja de $29.9\,\%$ a menos del $7\,\%$.
2. **NLMS y VS-LMS superan al LMS estándar, pero por poco entre ellos**: NLMS (AAE $= 4.72$ BPM, función objetivo 11.43) y VS-LMS (AAE $= 4.56$ BPM, función objetivo 11.32) funcionan mejor que LMS estándar (AAE $= 5.18$ BPM, función objetivo 12.88). Esto es consistente con lo planteado en el marco teórico: al normalizar el paso por la energía instantánea de los acelerómetros, estas variantes se adaptan mejor a los cambios de intensidad del movimiento dentro de una misma ventana. VS-LMS obtuvo el menor AAE y el menor porcentaje de *outliers* ($6.4\,\%$), por lo que fue el ganador en validación cruzada. Igualmente, su diferencia con NLMS es chica (0.16 BPM de AAE y 0.11 en la función objetivo), y no hicimos un análisis estadístico para saber si es significativa.
3. **El periodograma fue el estimador elegido**: En las tres variantes el optimizador eligió el periodograma con *zero-padding* por sobre el detector de picos de Elgendi. Una posible explicación es que, cuando quedan artefactos residuales en la señal limpia, la detección de picos en el tiempo es sensible a picos falsos o latidos deformados, que alteran la mediana de los intervalos entre latidos (IBI). El periodograma, en cambio, junta la energía periódica de todos los latidos de la ventana de 8 s en un solo pico en frecuencia, lo que lo hace más robusto.

B. Rendimiento en el conjunto de prueba

Una vez fijados los hiperparámetros con los datos de entrenamiento, evaluamos las tres variantes y la línea base sobre el conjunto de prueba (`IEEEPPG_TEST.ts`), que tiene 1328 ventanas de 10 participantes que el algoritmo no vio durante la optimización. En la Tabla III están las métricas, y agregamos la mediana del error absoluto (MedAE) para ver el comportamiento típico sin el efecto de los casos extremos.

Como se ve en la Tabla III, el conjunto de prueba es más difícil que el de entrenamiento: la línea base sin LMS tiene un AAE de 20.41 BPM y un $41.11\,\%$ de ventanas *outlier*, contra 12.52 BPM y $29.9\,\%$ en la validación cruzada. Una posible causa es que los movimientos de los participantes de prueba sean distintos a los de entrenamiento, algo que habría que verificar en la descripción de la base de datos. Aun así, los filtros adaptativos mejoran la estimación: el porcentaje de

TABLA II

HIPERPARÁMETROS SELECCIONADOS Y RENDIMIENTO EN VALIDACIÓN CRUZADA DE 5 *folds* POR PARTICIPANTE SOBRE EL CONJUNTO DE ENTRENAMIENTO (`IEEEPPG_TRAIN.ts`). EL AAE Y EL RMSE ESTÁN EXPRESADOS EN BPM, Y EL PORCENTAJE DE *outliers* CORRESPONDE A VENTANAS CON $|\hat{y} - y| > 10$ BPM.

Método	**Hiperparámetros LMS**	**Detector BPM**	**Obj.**	**AAE**	**RMSE**	**Outliers**
Sin LMS (Base)	—	Periodograma (8192, Hann)	24.66	12.52	22.45	29.9 %
LMS estándar	$M = 11,\ \mu = 0.00070$	Periodograma (4096, Hamming)	12.88	5.18	16.93	6.9 %
NLMS	$M = 22,\ \mu = 0.01288,\ \delta = 0.50$	Periodograma (4096, Hann)	11.43	4.72	14.75	6.6 %
VS-LMS	$M = 18,\ \mu_{\max} = 0.06558,\ \mu_{\min} = 0.00791,$ $\alpha = 0.98503,\ \gamma = 0.00053,\ \delta = 1.0$	**Periodograma** (8192**, Hamming)**	**11.32**	**4.56**	15.02	**6.4 %**

TABLA III

COMPARACIÓN DEL RENDIMIENTO EN EL CONJUNTO DE PRUEBA (`IEEEPPG_TEST.ts`, 1328 VENTANAS DE 10 PARTICIPANTES) ANTES DEL FILTRADO LMS Y CON CADA UNA DE LAS TRES VARIANTES OPTIMIZADAS.

Método	**Objetivo**	**AAE** (BPM)	**RMSE** (BPM)	**MedAE** (BPM)	**Outliers** (> 10 BPM)
Sin LMS (base)	40.26	20.41	34.93	3.29	41.11 %
LMS estándar	33.78	16.01	33.21	1.56	26.20 %
NLMS	**29.85**	**14.05**	**30.18**	1.53	**24.32 %**
VS-LMS (ganador CV)	33.28	15.76	32.84	**1.52**	25.98 %

outliers baja unos 15 puntos porcentuales (de 41.11 % a entre 24.32 % y 26.20 %), y la mediana del error se reduce a menos de la mitad, de 3.29 BPM a entre 1.52 y 1.56 BPM.

Esto quiere decir que en la gran mayoría de las ventanas la estimación es muy precisa (con el modelo ganador de CV, 983 de las 1328 ventanas, es decir el 74.02 %, tienen un error menor o igual a 10 BPM), pero el promedio queda arrastrado por un grupo chico de ventanas con errores muy grandes. Por esto la mejora en el AAE es bastante menor que en validación cruzada: entre 21.6 % y 31.2 % en prueba, contra hasta 63.6 %. Esta diferencia es importante, ya que indica que los hiperparámetros elegidos con los participantes de entrenamiento no generalizan igual de bien a participantes nuevos.

Es interesante comparar NLMS y VS-LMS en la Tabla III. VS-LMS ganó en validación cruzada y tiene la mejor mediana en prueba (MedAE $=$ 1.52 BPM), pero NLMS tiene el mejor rendimiento promedio en prueba (AAE $=$ 14.05 BPM, RMSE $=$ 30.18 BPM y 24.32 % de *outliers*). Hay dos posibles explicaciones. Primero, NLMS tiene menos hiperparámetros para ajustar (3 contra 5 de VS-LMS), lo que podría darle una mejor capacidad de generalización a participantes nuevos. Segundo, en ventanas de prueba con picos de ruido que no están correlacionados con el acelerómetro, el término $\gamma e^2[n]$ de VS-LMS puede subir el paso $\mu[n]$ hacia $\mu_{\max}$ aunque el filtro ya haya convergido dentro de la ventana, lo que agrega varianza en esas ventanas difíciles. No hicimos experimentos para confirmar ninguna de las dos. Además, las diferencias entre NLMS y VS-LMS son chicas comparadas con la variabilidad entre participantes, que vemos a continuación.

Para entender de dónde vienen los *outliers*, la Fig. 6 (izquierda) muestra el BPM estimado frente al BPM real, coloreado según cada uno de los 10 participantes, y la Tabla IV detalla las métricas por sujeto para el modelo ganador (`vs_lms`).

Se ve una gran diferencia entre participantes. En la mitad de los sujetos (3, 5, 6, 8 y 10) el algoritmo sigue bastante bien la recta ideal $\hat{y} = y$: el Sujeto 10 tiene un AAE de solo 3.05 BPM y un 5.0 % de *outliers*, y los Sujetos 3, 5 y 6 tienen errores medios cercanos a 8 BPM. En cambio, los errores grandes se concentran en los Sujetos 1, 2 y 4 (el Sujeto 1 tiene un 67.6 % de *outliers*). En la dispersión de la Fig. 6 se ve que para el Sujeto 1 (puntos azules, ritmo real entre 65 y 100 BPM) las estimaciones erróneas se agrupan alrededor de 140–180 BPM, que podría corresponder a la cadencia de los pasos al correr, o cerca de 40–50 BPM. Para el Sujeto 4 (puntos rojos, ritmo real alto, entre 150 y 175 BPM) los *outliers* caen hacia frecuencias bajas (45–120 BPM). Una posible causa es que el pulso óptico se pierda por momentos por un mal contacto del sensor con la muñeca, pero no lo podemos confirmar con estos datos.

C. Análisis paso a paso y casos de estudio

Para ver qué hace cada etapa de nuestra implementación sobre una ventana contaminada por movimiento, la Fig. 7 muestra el proceso completo para la ventana de prueba #479 (cuyo ritmo real de referencia es 169.5 BPM).

Siguiendo los paneles de la Fig. 7, podemos ver qué hace cada bloque:

- **Pasos 1 y 2 (preprocesamiento)**: En las señales crudas de PPG (*Step 1a*) se ven derivas lentas y grandes deflexiones entre $t = 0.5$ s y $t = 6.5$ s que coinciden en el tiempo con los impactos de los tres ejes del acelerómetro (*Step 1b*). El pasabanda Butterworth de fase cero (0.5–4.0 Hz) y la normalización (*Steps 2a y 2b*) sacan el nivel continuo y llevan todos los canales a varianza unitaria, pero los artefactos que están dentro de la banda cardíaca siguen ahí.
- **Paso 3 (LMS en paralelo y fusión por SNR)**: En *Step 3a*, el filtro VS-LMS ($M = 18$) estima el artefacto de movimiento $\hat{m}_1[n]$ (línea roja punteada) a partir de los tres ejes del acelerómetro, y lo resta de la señal primaria $d_1[n]$ para obtener la señal limpia $e_1[n]$ (línea verde). En *Step 3b*, la fusión calcula el SNR espectral de los dos canales filtrados: el segundo canal tiene un SNR mucho mayor ($\text{SNR}_2 = 0.81$ contra $\text{SNR}_1 = 0.32$), entonces recibe un peso $w_2 = 0.72$ frente a $w_1 = 0.28$, y la señal fusionada $e_{\text{fused}}[n]$ queda más regular.

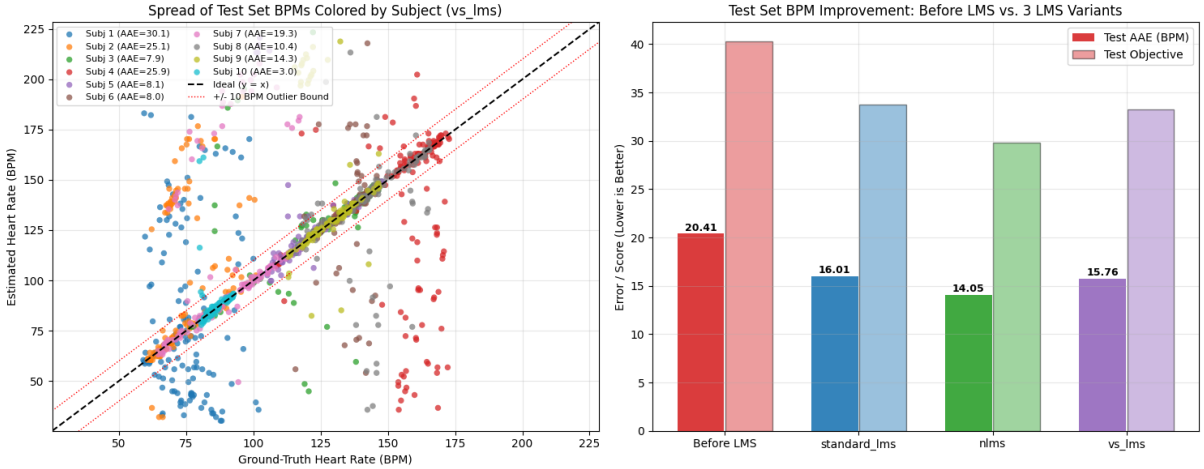


Fig. 6. Izquierda: dispersión de las estimaciones de BPM frente al valor real de ECG en el conjunto de prueba, coloreadas por participante, para el modelo ganador en validación cruzada (`vs_lms`). Derecha: comparación del AAE y la función objetivo en el conjunto de prueba entre la señal sin LMS y las tres variantes de LMS (esta imagen fue creada utilizando nuestro código).

TABLA IV
DESGLOSE DEL RENDIMIENTO POR PARTICIPANTE EN EL CONJUNTO DE PRUEBA (`IEEEPPG_TEST.TS`) UTILIZANDO EL MODELO GANADOR (`VS_LMS` + PERIODOGRAMA).

Participante (prueba)	**Ventanas**	**AAE (BPM)**	**Función objetivo**	**Outliers (>10 BPM)**
Sujeto 1	142	30.13	55.60	67.6 %
Sujeto 2	137	25.10	49.64	38.7 %
Sujeto 3	144	7.91	18.34	11.8 %
Sujeto 4	152	25.90	52.50	36.2 %
Sujeto 5	101	8.12	19.90	9.9 %
Sujeto 6	157	8.02	17.48	17.8 %
Sujeto 7	132	19.27	41.20	23.5 %
Sujeto 8	142	10.37	22.81	19.0 %
Sujeto 9	121	14.30	31.57	19.0 %
Sujeto 10	100	3.05	8.10	5.0 %

- **Paso 4 (periodograma antes y después de LMS)**: En el espectro (*Step 4b*), antes del LMS (curva roja) dominan dos picos de interferencia en 47.6 BPM y alrededor de 98 BPM, y por esto se estima 47.6 BPM (un error de 121.9 BPM). Después del LMS (curva verde) esos picos, que están correlacionados con el acelerómetro, se reducen y el pico dominante pasa a ser la frecuencia cardíaca real, en 168.5 BPM, con lo que el error baja a 1.0 BPM.

Finalmente, la Fig. 8 compara el comportamiento del filtro en el mejor caso del conjunto de prueba (ventana #667, izquierda) y en el caso atípico más extremo (ventana #481, derecha).

En el caso exitoso (ventana #667), el participante hace un movimiento rítmico continuo de alta amplitud, que se ve claramente en los tres ejes del acelerómetro. Antes del LMS este movimiento contamina las señales de PPG y engaña al periodograma, que estima 179.4 BPM cuando el valor real es 111.7 BPM. Como la interferencia es estacionaria y está muy correlacionada con el acelerómetro, el filtro adaptativo la cancela casi por completo dentro de la ventana y estima 111.7 BPM (un error de solo 0.01 BPM).

En el caso *outlier* (ventana #481, ritmo real 168.6 BPM), en cambio, el acelerómetro muestra impactos bruscos y aislados, no estacionarios (sobre todo alrededor de $t = 1$ s y $t = 6.5$ s), que producen saturaciones momentáneas de gran amplitud en los dos fotodiodos. Estas distorsiones ópticas por desplazamientos bruscos del sensor probablemente son muy no lineales e impulsivas, y un filtro FIR lineal de orden fijo no logra cancelarlas durante los 8 s de la ventana. Como resultado, quedan oscilaciones lentas de mucha energía en $e_{\text{fused}}[n]$ que llevan el máximo del periodograma a 36.6 BPM (un error de 132.01 BPM).

V. CONCLUSIONES

En este trabajo diseñamos, implementamos y evaluamos un sistema para cancelar artefactos de movimiento en ventanas individuales de señales de fotopletismografía (PPG) de muñeca, usando filtros adaptativos MISO LMS con un acelerómetro triaxial como referencia. A partir de los experimentos con la base de datos IEEEPPG llegamos a varias conclusiones.

Primero de todo, el filtrado adaptativo es extremadamente importante frente al movimiento constante que está presente en las señales de PPG. Mientras que en tramos de reposo la

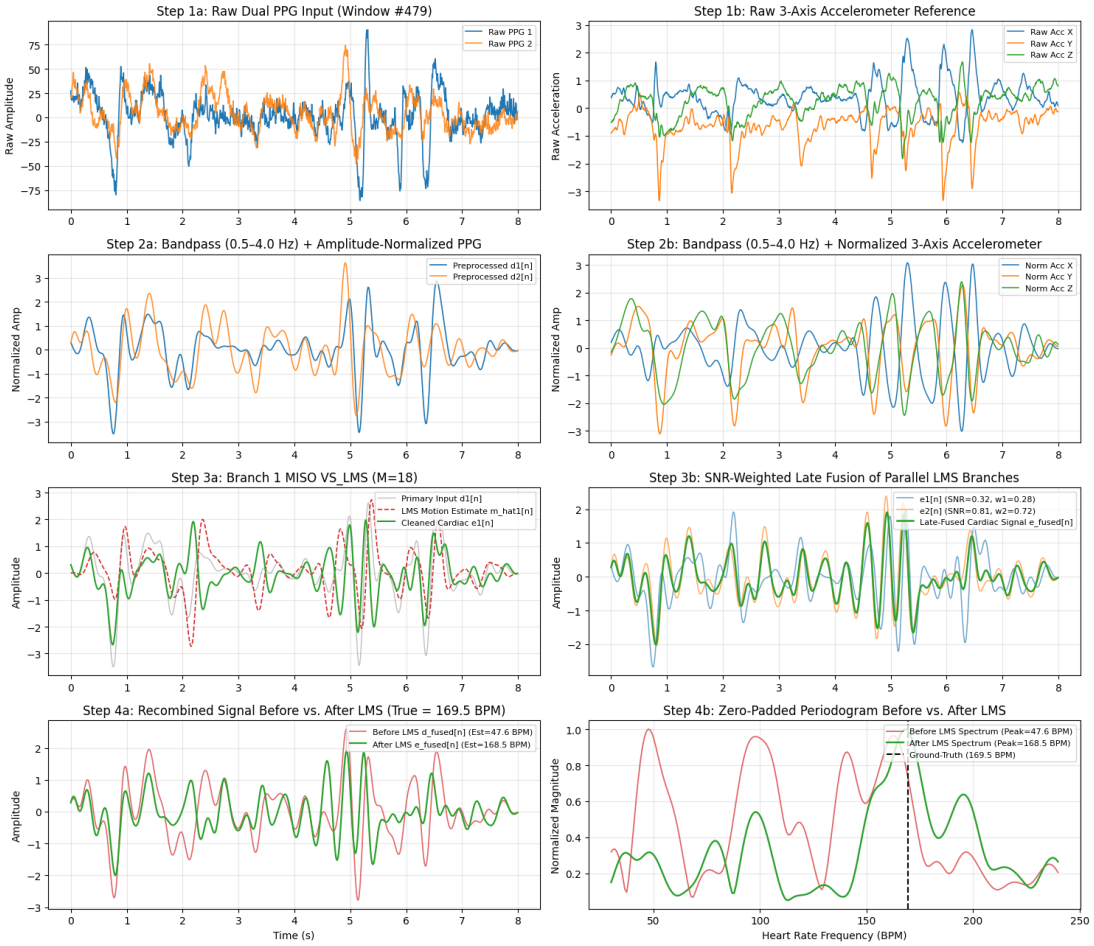


Fig. 7. Evolución paso a paso de la ventana de prueba #479 (BPM real = 169.5 BPM) a través de las cuatro etapas del sistema: señales crudas (Paso 1), filtrado pasabanda y normalización (Paso 2), cancelación adaptativa MISO VS-LMS y fusión ponderada por SNR (Paso 3), y comparación temporal y espectral antes y después de LMS (Paso 4) (esta imagen fue creada utilizando nuestro código).

señal de PPG preprocesada permite estimar adecuadamente el ritmo cardíaco, durante el ejercicio físico los artefactos de movimiento degradan severamente la estimación sin filtrar (AAE = 12.52 BPM en validación cruzada y 20.41 BPM en prueba, con hasta un 41.11 % de *outliers*). La incorporación del esquema de cancelación adaptativa de interferencia redujo el AAE de validación cruzada hasta 4.56 BPM (disminuyendo los *outliers* del 29.9 % al 6.4 %) y redujo la mediana del error absoluto en el conjunto de prueba de 3.29 BPM a 1.52 BPM, logrando estimaciones dentro del margen de ±10 BPM en el 74.02 % de las ventanas de prueba.

Otra conclusión importante es que simplemente utilizar LMS no es suficiente, sino que hace falta implementar sus variantes. Esto es debido a que las dos variantes normalizadas en potencia (NLMS y VS-LMS) superaron de manera consistente al LMS estándar tanto en validación cruzada como en el conjunto de prueba, confirmando la necesidad de independizar el paso de adaptación de las variaciones de energía del acelerómetro dentro de cada ventana. Al comparar VS-LMS con NLMS, se observó que VS-LMS obtuvo el mejor desempeño en validación cruzada (AAE = 4.56 BPM) y la menor mediana de error en prueba (1.52 BPM), pero NLMS alcanzó el menor error medio global en el conjunto de prueba (AAE = 14.05 BPM frente a 15.76 BPM de VS-LMS, y 24.32 % de *outliers*). Esto demuestra que NLMS ofrece un excelente compromiso entre velocidad de adaptación en una ventana aislada y robustez de generalización con solo tres hiperparámetros (M, μ y δ).

Otro resultado interesante de esta aplicación en particular es la combinación de señales primarias cuando tenés más que uno. Como la base de datos que fue implementada tenía más que una señal primaria, ofrecía otra manera de optimizar los algoritmos usados. Filtrar los dos fotodiodos en paralelo y combinar sus señales de error según su SNR espectral permite darle menos peso al canal más afectado cuando el movimiento perjudica solo a uno de los sensores, como en la ventana #479. Además, el optimizador eligió el periodograma con *zero-padding* por sobre el detector de picos de Elgendi en las tres variantes de LMS.

Finalmente, este trabajo también desveló las limitaciones del análisis de ventanas aisladas. Como cada ventana de 8 s se analiza de forma independiente, sin contexto adicional, los

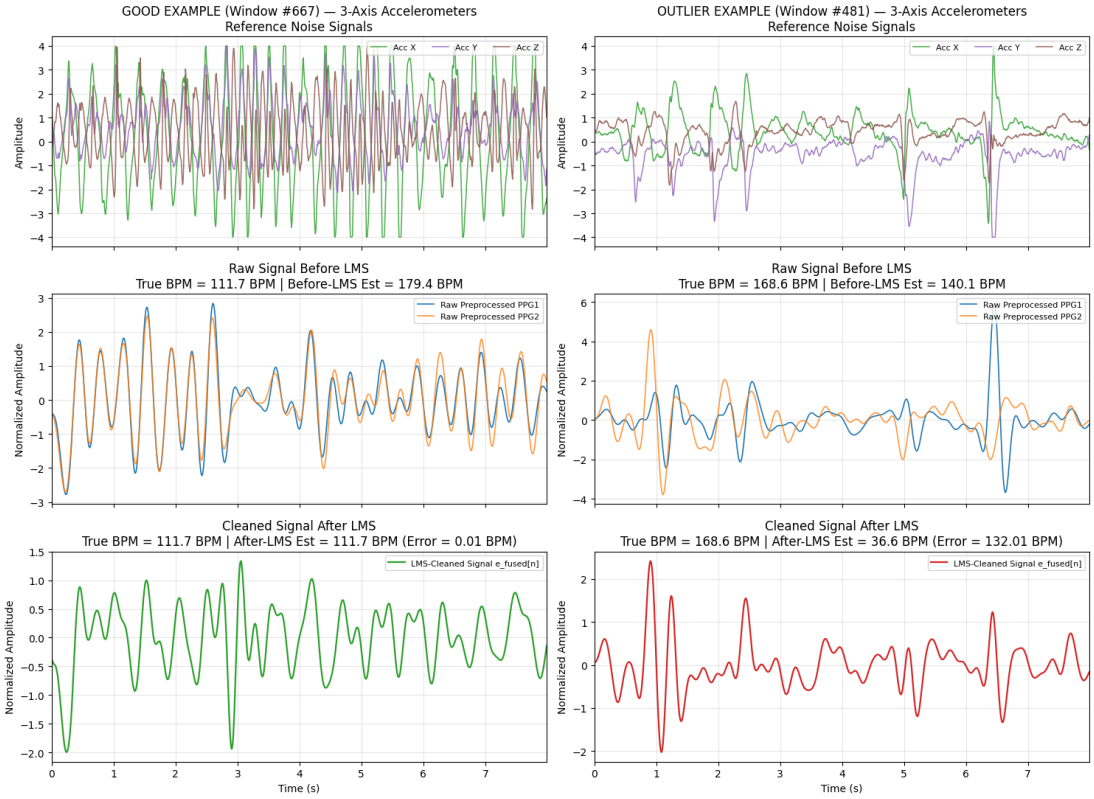


Fig. 8. Comparación entre un caso de detección exitosa (izquierda, ventana #667) y un caso atípico u *outlier* (derecha, ventana #481) en el conjunto de prueba, mostrando de arriba hacia abajo: las señales de referencia del acelerómetro triaxial, las señales de PPG preprocesadas antes de LMS y la señal cardíaca limpia $e_{\text{fused}}[n]$ después de LMS (esta imagen fue creada utilizando nuestro código).

casos atípicos que estudiamos aparecen cuando hay impactos impulsivos o desplazamientos bruscos del sensor sobre la muñeca, cuya relación con la aceleración no es lineal, o cuando la componente cardíaca en los dos fotodiodos es tan débil que un pico de movimiento residual domina el periodograma de esa ventana.

Como trabajo a futuro, dentro de este mismo esquema de procesamiento por ventana individual se podrían probar algoritmos adaptativos con convergencia más rápida, como RLS (*Recursive Least Squares*), o filtros adaptativos no lineales que puedan captar las distorsiones ópticas que un filtro FIR lineal no puede modelar.

Referencias

[1] C. W. Tan, C. Bergmeir, F. Petitjean, and G. I. Webb, "IEEEPPG dataset," Zenodo, 2020, derivado de la IEEE Signal Processing Cup 2015. [Online]. Available: https://zenodo.org/records/3902710

[2] M. S. Ressl, "Material de clase: Procesamiento adaptativo de señales," Instituto Tecnológico de Buenos Aires (ITBA), Diapositivas de la materia 22.46, 2026.

[3] M. Elgendi, I. Norton, M. Brearley, D. Abbott, and D. Schuurmans, "Systolic peak detection in acceleration photoplethysmograms measured from emergency responders in tropical conditions," *PLOS ONE*, vol. 8, no. 10, p. e76585, 2013. [Online]. Available: https://doi.org/10.1371/journal.pone.0076585

[4] S. Haykin, *Adaptive Filter Theory*, 5th ed. Pearson, 2014.

[5] Z. Zhang, Z. Pi, and B. Liu, "TROIKA: A general framework for heart rate monitoring using wrist-type photoplethysmographic signals during intensive physical exercise," *IEEE Transactions on Biomedical Engineering*, vol. 62, no. 2, pp. 522–531, Feb. 2015.

[6] M. T. Islam, I. Zabir, S. T. Ahamed, M. T. Yasar, C. Shahnaz, and S. A. Fattah, "A time-frequency domain approach of heart rate estimation from photoplethysmographic (PPG) signal," arXiv:1704.00224, 2017. [Online]. Available: https://arxiv.org/abs/1704.00224

[7] R. Yousefi, M. Nourani, and I. Panahi, "Adaptive cancellation of motion artifact in wearable biosensors," in *Proc. 34th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, San Diego, CA, USA, Aug. 2012, pp. 2004–2008. [Online]. Available: https://ecs.utdallas.edu/research/researchlabs/QoLT/files/pdfs/EMBC12_Adaptive.pdf

[8] M. R. Ram, K. V. Madhav, E. H. Krishna, N. R. Komalla, and K. A. Reddy, "A novel approach for motion artifact reduction in PPG signals based on AS-LMS adaptive filter," *IEEE Transactions on Instrumentation and Measurement*, vol. 61, no. 5, pp. 1445–1457, May 2012. [Online]. Available: https://ieeexplore.ieee.org/document/6111474

[9] T. Schack, C. Sledz, M. Muma, and A. M. Zoubir, "A new method for heart rate monitoring during physical exercise using photoplethysmographic signals," in *Proc. 23rd European Signal Processing Conference (EUSIPCO)*, Nice, France, 2015, pp. 2716–2720. [Online]. Available: https://new.eurasip.org/Proceedings/Eusipco/Eusipco2015/papers/1570102009.pdf

[10] M. Wang, Z. Li, Q. Zhang, and G. Wang, "Removal of motion artifacts in photoplethysmograph sensors during intensive exercise for accurate heart rate calculation based on frequency estimation and notch filtering," *Sensors*, vol. 19, no. 15, p. 3312, 2019. [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC6696451

[11] S. S. Gudibandi, "PPG heart rate detection in the presence of motion artifacts," Master's thesis, Texas A&M University, College Station, TX, USA, Aug. 2016. [Online]. Available: https://oaktrust.library.tamu.edu/bitstream/1969.1/187370/1/GUDIBANDI-THESIS-2016.pdf